



OPTIMASI TEKNIK MACHINE LEARNING DALAM KLASIFIKASI TINGKAT OBESITAS

IMPLEMENTASI MACHINE LEARNING DENGAN OPTIMASI
SVM DAN INTEGRASI DECISION SUPPORT SYSTEM (DSS)



Karakteristik Dataset

Sumber Data

UCI Machine Learning Repository

Jumlah Observasi

2.111 baris

Variabel Target (NObeyesdad)

7 tingkatan berat badan sesuai standar WHO (dari Insufficient Weight, Normal, hingga Obesity Type III).

Dataset

Atribut Dataset (17 Fitur)

- Karakteristik Demografi & Fisik: Gender, Age, Height, Weight.
- FAVC (Konsumsi makanan tinggi kalori) & FCVC (Frekuensi makan sayur).
- NCP (Jumlah makan utama) & CAEC (Kebiasaan ngemil di antara waktu makan).
- CH2O (Konsumsi air minum) & CALC (Konsumsi alkohol).
- SMOKE (Kebiasaan merokok) & SCC (Monitoring kalori mandiri).
- FAF (Frekuensi aktivitas fisik) & TUE (Waktu penggunaan gawai/gaya hidup sedenter).
- MTRANS (Moda transportasi yang digunakan).


Audit Data & Preprocessing

- 0% missing value pada seluruh fitur (Dataset bersih).
- 24 baris duplikat dihapus untuk menjaga objektivitas evaluasi, menyisakan 2.087 baris

Analisis Pencilan (Outlier):

Ditemukan beberapa nilai ekstrem pada fitur Age dan Weight. Outlier tidak dihapus karena merupakan variasi klinis riil di dunia nyata, bukan kesalahan input data.

Audit Data



Audit Data & Preprocessing

Penyandian Variabel Kategorikal (Encoding):

- Label Encoding digunakan untuk mengonversi 7 tingkatan target (NObeyesdad) menjadi angka 0 s.d. 6.
- One-Hot Encoding diterapkan pada fitur multikelas seperti MTRANS untuk mencegah bias matematika algoritma.

Feature Scaling

Menggunakan StandardScaler (Z-score) untuk menyamakan rentang nilai fitur numerik

Preprocessing

Pencegahan Kebocoran Data

Dataset dipisahkan terlebih dahulu menggunakan train_test_split (80% Train, 20% Test) dengan parameter stratify=y.

```
=== CONTOH FITUR SEBELUM PREPROCESSING (Masing-masing 2 baris awal) ===
      Age      Height      Weight Gender
1573  25.883749  1.767077  114.133149  Male
1598  30.686701  1.644517  100.004418  Male

=== CONTOH FITUR SESUDAH PREPROCESSING (Masing-masing 2 baris awal) ===
      Age      Height      Weight Gender_Male
1573  0.248290  0.705537  1.045026         True
1598  1.008501 -0.608067  0.505277         True
```

Model

Baseline

Skenario Pengujian: Pengujian awal menggunakan 3 algoritma berbeda dengan hyperparameter default bawaan pustaka Scikit-Learn dan divalidasi menggunakan Stratified 5-Fold Cross-Validation.


=== TABEL EVALUASI METRIK GABUNGAN (BASELINE MODEL) ===						
	Model	Accuracy	Precision (Macro)	Recall (Macro)	Macro-F1 Score	Balanced Accuracy
0	K-Nearest Neighbors (KNN)	0.834928	0.825429	0.827154	0.816343	0.827154
1	Gaussian Naive Bayes	0.500000	0.519477	0.488556	0.425072	0.488556
2	Support Vector Machine (SVM)	0.928230	0.924706	0.924713	0.924547	0.924713

Baseline

Model

Baseline

Skenario Pengujian: Pengujian awal menggunakan 3 algoritma berbeda dengan hyperparameter default bawaan pustaka Scikit-Learn dan divalidasi menggunakan Stratified 5-Fold Cross-Validation.



Baseline

Strategi Optimasi

Metode Optimasi: Menerapkan GridSearchCV dikombinasikan dengan Stratified 5-Fold Cross Validation murni di dalam area data latih.

Tujuan: Mencari titik keseimbangan matematika terbaik agar model memiliki kemampuan generalisasi yang tinggi dan terhindar dari overfitting.

=== TABEL PERBANDINGAN BASELINE VS OPTIMIZED ===					
	Model	Baseline Acc	Baseline F1	Optimized Accuracy	Optimized Macro-F1
0	K-Nearest Neighbors (KNN)	0.834928	0.816343	0.880383	0.872601
1	Gaussian Naive Bayes	0.500000	0.425072	0.636364	0.600555
2	Support Vector Machine (SVM)	0.928230	0.924547	0.971292	0.970010


Model Terbaik Keseluruhan: Support Vector Machine (SVM) dengan parameter optimal: C=10, kernel='rbf', dan gamma='auto'.

Optimisasi

Analisis Kesalahan

Analisis Margin Kesalahan (2.88%):

- Kesalahan prediksi tidak terjadi secara acak, melainkan hanya terpusat pada batas marginal kelas yang saling bertetangga.
- Contoh kasus: Terjadi ambiguitas prediksi antara kelompok Overweight Level II dengan Obesity Type I.
- Penyebab: Individu yang berada pada batas ambang transisi Indeks Massa Tubuh (IMT) memiliki profil gaya hidup dan pola makan yang nyaris identik, sehingga membuat algoritma mengalami kesulitan minor dalam menarik garis batas keputusan (decision boundary).



Error
Analysis



THANK YOU

› End Slide