

LAPORAN
OPTIMASI TEKNIK MACHINE LEARNING DALAM KLASIFIKASI TINGKAT
OBESITAS BERDASARKAN KEBIASAAN MAKAN DAN KONDISI FISIK



Disusun oleh :

Muhammad Fatih Azzufar A11.2024.15672

PROGRAM STUDI S-1 TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2025

PENDAHULUAN

1.1 Latar Belakang

Obesitas telah menjadi tantangan kesehatan global krusial yang memicu tingginya angka penyakit tidak menular, seperti diabetes melitus tipe 2 dan penyakit kardiovaskular. Selama ini, pemantauan risiko obesitas di masyarakat cenderung reaktif, di mana penanganan klinis baru dilakukan saat gejala penyerta muncul atau indeks massa tubuh (IMT) sudah memburuk. Untuk mengatasi keterlambatan penanganan tersebut, teknologi *Machine Learning* hadir menawarkan solusi deteksi dini yang proaktif. Dengan menganalisis pola multidimensi dari data karakteristik demografi pengguna, kebiasaan makan, dan tingkat aktivitas fisik, algoritma klasifikasi dapat memprediksi tingkat risiko obesitas seseorang secara cepat dan otomatis sebelum kondisi klinisnya bertambah parah.

Meskipun teknologi kecerdasan buatan sangat menjanjikan, implementasinya harus tetap menjunjung tinggi etika dan mitigasi risiko. Model prediktif yang dibangun sama sekali tidak boleh diklaim atau digunakan sebagai alat diagnosis medis final yang menggantikan peran dokter atau ahli gizi. Oleh karena itu, aplikasi yang dikembangkan dalam proyek eksperimen ini diposisikan secara tegas sebagai *Decision Support System* (DSS) atau sistem penunjang keputusan. Sistem ini berfungsi murni sebagai instrumen skrining awal yang obyektif untuk membantu merancang program intervensi gaya hidup sehat yang inklusif, adil, dan terhindar dari bias klasifikasi yang dapat merugikan pengguna.

1.2 Tujuan Proyek

Berdasarkan latar belakang permasalahan tersebut, proyek eksperimen dan implementasi *Machine Learning* ini dirancang untuk mencapai beberapa tujuan strategis berikut:

1. Membangun dan melatih model prediktif berbasis *Machine Learning* dengan membandingkan tiga algoritma utama—yaitu *K-Nearest Neighbors* (KNN), *Gaussian Naive Bayes*, dan *Support Vector Machine* (SVM)—untuk mengklasifikasikan status berat badan pengguna ke dalam 7 tingkatan obesitas secara akurat dan obyektif.
2. Mendongkrak performa dan stabilitas model melalui penerapan tiga teknik optimasi wajib, yaitu penanganan ketidakseimbangan data kelas (*class imbalance*) dengan SMOTE, pengujian validasi silang berstrata (*Stratified Cross-Validation*), serta pencarian parameter terbaik melalui *Hyperparameter Tuning* (*GridSearchCV*).
3. Menerapkan model pemenang ke dalam aplikasi web berbasis Streamlit yang bersih dan mudah digunakan agar masyarakat awam dapat melakukan skrining mandiri secara instan.
4. Menghasilkan laporan evaluasi eksperimen yang komprehensif, mencakup analisis kesalahan (*error analysis*) model, guna memberikan rekomendasi tindakan lanjut yang etis dan bebas dari bias kelompok tertentu.

1.3 Relevansi dengan Outcome-Based Education (OBE)

Proyek prediksi tingkat obesitas ini memiliki relevansi yang sangat erat dengan prinsip OBE melalui pemenuhan kriteria berikut:

- Selaras dengan catatan rubrik OBE, model yang sangat akurat belum tentu paling layak jika kinerjanya tidak stabil atau menghasilkan bias yang merugikan kelompok data tertentu. Melalui proyek ini, mahasiswa dilatih untuk

mementingkan metrik *Macro-F1 Score* dan keadilan model agar sistem aman digunakan sebagai alat bantu keputusan.

- Prinsip OBE menuntut mahasiswa mampu mempertanggungjawabkan kodenya secara ilmiah. Eksperimen ini mencerminkan alur berpikir tersebut, mulai dari perumusan hipotesis eksperimen, alasan akademis di balik pemilihan strategi optimasi, investigasi terhadap kegagalan prediksi (*error analysis*), hingga penarikan kesimpulan yang logis.
- *Outcome* konkret dari proyek ini dibuktikan dengan keberhasilan penyusunan arsitektur perangkat lunak yang modular serta perilisan aplikasi web penunjang keputusan (*Decision Support System*) yang siap pakai.

STUDI LITERATUR

2.1 Penanganan Kelas Tidak Seimbang dan Metrik Evaluasi

Penelitian Setiawan et al. (2026) membuktikan bahwa metrik akurasi tunggal pada dataset multikelas sering kali menghasilkan prediksi yang bias terhadap kelas mayoritas. Sebagai solusinya, mereka merekomendasikan penggunaan *Stratified Cross-Validation* dan metrik *Macro-F1 Score* untuk evaluasi yang lebih adil. Meskipun studi tersebut mengkaji data *drop-out* mahasiswa, pendekatan matematis ini secara langsung diadopsi pada proyek ini untuk menangani 7 kelas tingkat obesitas. Tujuannya adalah untuk menjamin bahwa model yang dihasilkan stabil, tidak mendiskriminasi kelas tertentu, dan memenuhi standar keadilan (*fairness*) sesuai rubrik *Outcome-Based Education* (OBE).

2.2 Optimasi Hyperparameter berbasis Grid Search

Studi komparatif oleh Al Hakim et al. (2026) menyimpulkan bahwa algoritma *Grid Search* memberikan hasil optimasi parameter yang jauh lebih stabil dan superior dibandingkan *Random Search* pada pemrosesan dataset yang kompleks. Landasan empiris ini diaplikasikan dalam eksperimen proyek ini melalui penggunaan *GridSearchCV* untuk memetakan kombinasi *hyperparameter* terbaik pada algoritma *Support Vector Machine* (SVM). Penerapan optimasi ini menjadi bukti jejak berpikir ilmiah untuk memastikan model mencapai performa maksimal dan terhindar dari *overfitting* sebelum di-deploy ke dalam aplikasi.

DATASET DAN DATA DICTIONARY

3.1 Sumber Data

Dataset yang digunakan dalam eksperimen ini berjudul "*Estimation of Obesity Levels Based On Eating Habits and Physical Condition*". Dataset publik ini diakses dan diunduh melalui repositori *UCI Machine Learning Repository*. Secara demografis, data ini pada awalnya dikumpulkan dari individu yang berasal dari negara Meksiko, Peru, dan Kolombia, yang mencakup rentang usia remaja hingga dewasa.

3.2 Fitur dan Target Variabel (*Data Dictionary*)

Dataset ini dilengkapi dengan 16 fitur prediktor independen yang secara logis dibagi menjadi dua kategori utama yang memengaruhi tingkat obesitas:

- Atribut Kondisi Fisik (*Physical Condition*): Meliputi data demografis dan antropometrik dasar seperti Umur (*Age*), Tinggi Badan (*Height*), dan Berat Badan (*Weight*). Selain itu, terdapat fitur turunan terkait aktivitas fisik seperti Frekuensi aktivitas fisik harian (*FAF*) dan Waktu penggunaan perangkat teknologi (*TUE*).

- Atribut Kebiasaan Makan (*Eating Habits*): Meliputi pola diet individu, seperti Frekuensi konsumsi sayuran harian (*FCVC*), Jumlah makan utama (*NCP*), Konsumsi air harian (*CH2O*), Konsumsi makanan tinggi kalori (*FAVC*), hingga kebiasaan ngemil (*CAEC*) dan konsumsi alkohol (*CALC*).

Variabel Target (Output Klasifikasi): **NOBeyesdad**

Variabel ini bersifat kategorikal multikelas yang mengindikasikan tingkat obesitas individu berdasarkan kalkulasi Indeks Massa Tubuh (IMT) menurut standar WHO.

Target ini memiliki 7 kelas yang terdistribusi ke dalam:

1. *Insufficient Weight* (Kekurangan Berat Badan)
2. *Normal Weight* (Berat Badan Normal)
3. *Overweight Level I* (Kelebihan Berat Badan Tahap I)
4. *Overweight Level II* (Kelebihan Berat Badan Tahap II)
5. *Obesity Type I* (Obesitas Tipe I)
6. *Obesity Type II* (Obesitas Tipe II)
7. *Obesity Type III* (Obesitas Tipe III)

3.3 Etika dan Privasi Data

Penanganan data di ranah kesehatan menuntut tingkat kepatuhan etis yang sangat ketat. Dataset ini dipastikan aman dari pelanggaran privasi penggunaanya karena peneliti asli telah menerapkan prinsip Anonimisasi Data (*Data Anonymization*). Tidak ada informasi identitas pribadi (*Personally Identifiable Information* / PII) seperti nama, alamat email, alamat IP, maupun nomor rekam medis yang dicantumkan dalam *file* CSV.

Dari sudut pandang etika (*AI Ethics*), model yang dilatih menggunakan dataset ini tidak boleh dikomersialkan secara sepihak untuk kebijakan diskriminatif, seperti penentuan premi asuransi kesehatan dengan mengandalkan prediksi otomatis algoritma. Oleh karena itu, *Decision Support System* yang dibangun melalui proyek ini menyertakan label "Peringatan Etis (*Ethical Disclaimer*)" pada antarmuka (*User Interface*) untuk mengedukasi pengguna bahwa *output* prediksi ini hanyalah bahan skrining awal, bukan diagnosis medis mutlak.

3.4 Batasan Penggunaan Dataset (*Limitations of Use*)

Terdapat dua batasan fundamental pada dataset ini yang harus dipertimbangkan ketika menginterpretasikan akurasi model akhir:

1. Bias Demografi Geografis (*Geographical Bias*): Data empiris di dalam dataset ini dikumpulkan secara eksklusif dari demografi masyarakat Amerika Latin (Meksiko, Peru, dan Kolombia). Terdapat potensi pergeseran distribusi data (*data drift*) jika model dipaksakan untuk memprediksi individu dari demografi ras Asia atau Eropa, mengingat terdapat perbedaan pola genetik, jenis metabolisme, dan kebiasaan diet pangan lokal.
2. Implikasi Proporsi Data Sintetis: Mengingat 77% observasi dalam dataset adalah hasil generasi algoritma (*Synthetic Data*), pola korelasi antar-fitur mungkin sedikit terlalu teratur secara matematis (*mathematically smooth*) dibandingkan anomali data di dunia nyata yang penuh *noise*. Hal ini mengharuskan berhati-hati agar tidak terlena dengan tingginya nilai akurasi evaluasi, melainkan tetap harus mengujinya dengan skenario data masukan acak di luar sampel latih.

AUDIT DATA DAN PREPROCESSING

4.1 Audit Kualitas Data: *Missing Value* dan Duplikat

Sebelum melakukan manipulasi fitur, dilakukan audit data deskriptif terhadap 2.111 observasi awal untuk mendeteksi cacat data berupa nilai yang hilang (*missing values*) dan baris data yang redundan (duplikat).

- *Missing Value Analysis*: Hasil audit menunjukkan bahwa dataset ini memiliki 0% *missing value* pada seluruh 17 atribut. Hal ini dikarenakan dataset dari repositori UCI telah melalui tahap kurasi yang bersih oleh peneliti aslinya, sehingga tidak diperlukan operasi imputasi nilai.
- *Duplicate Rows Handling*: Proses pengecekan mendeteksi adanya 24 baris data duplikat yang identik di seluruh fiturnya. Kemunculan data duplikat ini merupakan konsekuensi logis dari proses replikasi matematis saat peneliti asli menghasilkan data sintesis menggunakan filter algoritma SMOTE. Untuk menjaga objektivitas evaluasi dan mencegah model "menghafal" data yang sama, 24 baris duplikat ini dieliminasi dari dataset, sehingga menyisakan 2.087 observasi unik untuk tahap eksperimen selanjutnya.

4.2 Penanganan Pencilan (*Outlier Analysis*)

Dalam proyek ini, pencilan tersebut tidak dihapus. Dari sudut pandang klinis medis, nilai-nilai ekstrem tersebut bukan merupakan kesalahan input (*human error*), melainkan representasi riil dari variasi biologis populasi manusia di dunia nyata (terdapat individu yang memang berusia senja atau memiliki berat badan sangat ekstrem yang menderita obesitas tingkat lanjut). Penghapusan pencilan ini justru akan mengurangi sensitivitas model dalam mendeteksi kasus-kasus klinis kritis. Masalah kerentanan algoritma terhadap pencilan ini nantinya akan diselesaikan di tingkat model, yaitu dengan memilih algoritma *Support Vector Machine* (SVM) yang menggunakan *Soft Margin* (parameter penalti c) dan kernel RBF, yang secara matematis sangat toleran dan *robust* terhadap keberadaan pencilan.

4.3 Rekayasa Fitur: Penyandian Variabel Kategorikal (*Encoding*)

Algoritma *Machine Learning* berbasis matematika (terutama SVM dan KNN) hanya dapat memproses input berupa angka numerik. Oleh karena itu, fitur-fitur kategorikal pada dataset ini harus disandikan (*encoding*) terlebih dahulu:

1. Penyandian Target (*Label Encoding*): Atribut target *NOBeyesdad* yang berisi 7 tingkatan berat badan disandikan secara ordinal menjadi nilai integer dari 0 s.d. 6. Hal ini direkam ke dalam berkas `label_encoder.joblib`.
2. Penyandian Fitur Kategorikal (*Categorical Feature Encoding*): Atribut dengan skala biner (*Gender*, *family_history_with_overweight*, *FAVC*, *SMOKE*, *SCC*) diubah menjadi nilai 0 dan 1. Sementara untuk atribut multikelas (*CAEC*, *CALC*, *MTRANS*), diterapkan kombinasi antara *Ordinal Encoding* dan *One-Hot Encoding* di dalam pipeline backend guna menghindari asumsi salah oleh model bahwa suatu moda transportasi memiliki nilai matematika yang lebih tinggi dari moda lainnya.

4.4 Penskalaan Fitur (*Feature Scaling*)

Dataset ini memiliki rentang nilai antarfitur numerik yang sangat timpang. Sebagai contoh, fitur *Height* berada pada rentang desimal yang kecil (1.4 s.d. 2.0 meter), sedangkan fitur *Weight* berada pada rentang ratusan (39 s.d. 173 kilogram). Algoritma berbasis jarak seperti KNN dan berbasis margin seperti SVM akan mengalami kegagalan

fatal jika data ini tidak diskalakan; fitur *Weight* akan mendominasi perhitungan fungsi jarak matematika secara tidak adil, membuat fitur *Height* dan *Age* menjadi tidak terbaca kontribusinya oleh model.

Untuk mengatasi hal tersebut, diterapkan metode **StandardScaler** (Standardisasi Z-score) yang mentransformasikan seluruh fitur numerik sehingga memiliki nilai rata-rata (*mean*) = 0 dan standar deviasi (*standard deviation*) = 1. Transformasi ini dirumuskan sebagai:

$$Z = \frac{x - \mu}{\sigma}$$

Parameter skalasi disimpan secara permanen ke dalam file `scaler.joblib` agar dapat digunakan kembali pada saat inferensi aplikasi web Streamlit.

4.5 Evaluasi Ketidakseimbangan Kelas (*Class Imbalance*)

Dataset ini memiliki distribusi variabel target yang relatif seimbang (berkisar 270 s.d. 350 sampel per kelas) karena peneliti aslinya telah menerapkan teknik SMOTE sebelum mempublikasikannya ke UCI Repository. Guna memastikan proporsi ideal dari 7 kelas tingkat obesitas ini tetap terjaga dengan adil selama proses pengujian, eksperimen ini wajib menggunakan metode pembagian data berbasis Stratified K-Fold Cross-Validation. Pendekatan ini menjamin setiap lipatan (*fold*) data memiliki representasi kelas yang seimbang sehingga model terhindar dari bias prediksi.

4.6 Pencegahan Kebocoran Data (*Data Leakage*)

Data Leakage dihindari secara ketat agar nilai performa model yang dihasilkan objektif dan tidak tinggi palsu. Protokol isolasi data pada arsitektur kode diterapkan melalui dua langkah:

1. Pemisahan Awal: Dataset dipisah terlebih dahulu menjadi 80% data latih dan 20% data uji menggunakan fungsi `train_test_split(stratify=y)`.
2. Isolasi Skalasi: Proses `.fit()` pada `StandardScaler` hanya dilakukan secara eksklusif pada data latih. Data uji hanya ditransformasikan menggunakan parameter yang diekstrak dari data latih tanpa ikut memengaruhi proses standardisasi.

DESAIN EKSPERIMEN

5.1 Skenario Pembagian Data (*Data Splitting*)

Dataset yang telah melalui tahap *preprocessing* dipisahkan menjadi dua bagian utama menggunakan fungsi `train_test_split` dari pustaka Scikit-Learn. Proporsi pembagian yang ditetapkan adalah 80% untuk Data Latih (*Train Set*) dan 20% untuk Data Uji (*Test Set*). Guna mempertahankan distribusi kelas yang sudah relatif seimbang, parameter `stratify=y` diaktifkan. Hal ini menjamin bahwa porsi dari ketujuh kelas tingkat obesitas pada Data Uji sama persis dengan proporsinya di Data Latih, sehingga evaluasi akhir benar-benar merepresentasikan kemampuan generalisasi model secara adil.

5.2 Pengujian Model *Baseline* (Dasar)

Sebagai tolok ukur awal, eksperimen ini membandingkan tiga algoritma klasifikasi dengan pendekatan matematis yang berbeda menggunakan hyperparameter *default* (bawaan library). Ketiga algoritma tersebut adalah:

1. K-Nearest Neighbors (KNN): Mewakili algoritma berbasis jarak spasial (*distance-based*).
2. Gaussian Naive Bayes (GNB): Mewakili algoritma probabilistik berbasis teorema Bayes.
3. Support Vector Machine (SVM): Mewakili algoritma berbasis margin geometris linier dan non-linier.

Pengujian *baseline* ini krusial untuk melihat performa mentah algoritma sebelum intervensi optimasi diberikan, sekaligus menjadi justifikasi logis apakah *hyperparameter tuning* yang dilakukan selanjutnya benar-benar memberikan nilai tambah atau tidak.

5.3 Cross-Validation (Validasi Silang)

Untuk mencari parameter terbaik tanpa menyentuh dan membocorkan Data Uji (20%), proses pencarian dilakukan murni di dalam area Data Latih (80%) menggunakan metode Stratified 5-Fold Cross-Validation. Data latih dipecah lagi menjadi 5 lipatan (*fold*) secara berstrata. Algoritma akan dilatih pada 4 lipatan dan divalidasi pada 1 lipatan sisanya secara bergantian sebanyak 5 kali. Nilai evaluasi yang diambil adalah nilai rata-rata dari kelima iterasi tersebut. Pendekatan ini memastikan model terhindar dari *overfitting* karena performa divalidasi pada variasi data yang berbeda-beda.

5.4 Hyperparameter Grid dan Optimasi

Tahap optimasi dilakukan menggunakan algoritma *GridSearchCV*, yang akan mengeksekusi metode *brute-force* sistematis untuk menguji seluruh kemungkinan kombinasi parameter pada *grid* pencarian. Ruang pencarian difokuskan pada model SVM dan KNN untuk mendongkrak kemampuannya:

- Grid Pencarian SVM:
 - C (Parameter Penalti): [0.1, 1, 10, 100]
 - kernel (Fungsi Transformasi): ['linear', 'rbf', 'poly']
 - gamma (Koefisien Kernel): ['scale', 'auto']
- Grid Pencarian KNN:
 - n_neighbors (Jumlah Tetangga): [3, 5, 7, 9]
 - weights (Bobot Jarak): ['uniform', 'distance']

(Catatan: Gaussian Naive Bayes tidak melalui *tuning parameter grid* yang kompleks karena sifat matematisnya yang parametrik standar tanpa banyak parameter eksternal.)

5.5 Metrik Evaluasi Utama

Sesuai dengan tinjauan literatur (Setiawan et al., 2026) dan prinsip keadilan model pada standar *Outcome-Based Education* (OBE), evaluasi tidak boleh bergantung pada metrik Akurasi semata. Eksperimen ini menetapkan dua metrik utama:

1. Akurasi (*Overall Accuracy*): Digunakan untuk mengukur persentase total prediksi yang benar dari keseluruhan data uji. Metrik ini valid digunakan sebagai acuan dasar karena dataset telah berada dalam kondisi kelas yang seimbang.
2. Macro-F1 Score: Berfungsi sebagai metrik penentu utama keadilan model (*model fairness*). *Macro-F1* menghitung nilai *Harmonic Mean* dari *Precision* dan *Recall* untuk setiap kelas secara terpisah, lalu merata-ratakannya tanpa memberikan pembobotan lebih pada kelas dengan jumlah sampel terbanyak. Jika nilai *Macro-F1*

sejalan atau mendekati nilai Akurasi, hal tersebut membuktikan secara empiris bahwa model tidak bias atau mendiskriminasi kelas tertentu.

HASIL EKSPERIMEN DAN ANALISIS PERFORMA MODEL

6.1 Hasil Eksperimen Model Baseline

Eksperimen tahap pertama dilakukan dengan melatih tiga algoritma (*K-Nearest Neighbors*, *Gaussian Naive Bayes*, dan *Support Vector Machine*) menggunakan *hyperparameter* bawaan (*default*) dari pustaka Scikit-Learn. Hasil pengujian *baseline* pada 20% Data Uji dapat dilihat pada gambar berikut:

	Model	Accuracy	Precision (Macro)	Recall (Macro)	Macro-F1 Score	Balanced Accuracy
0	K-Nearest Neighbors (KNN)	0.834928	0.825429	0.827154	0.816343	0.827154
1	Gaussian Naive Bayes	0.500000	0.519477	0.488556	0.425072	0.488556
2	Support Vector Machine (SVM)	0.928230	0.924706	0.924713	0.924547	0.924713

Berdasarkan gambar tersebut menunjukkan dominasi absolut bahkan sebelum dilakukan optimasi, dengan akurasi 92%. Sebaliknya, *Gaussian Naive Bayes* (GNB) mengalami kegagalan performa yang signifikan (akurasi 50.0%). Hal ini terjadi karena GNB memiliki asumsi dasar bahwa seluruh fitur prediktor bersifat independen (tidak saling berkaitan). Dalam kasus medis atau gaya hidup riil, fitur seperti Berat Badan (*Weight*) tentu memiliki korelasi kuat dengan Frekuensi Olahraga (*FAF*) dan Konsumsi Kalori (*FAVC*), sehingga asumsi independensi pada GNB menjadi tidak valid untuk dataset ini.

6.2 Hasil Eksperimen Optimasi (*Hyperparameter Tuning*)


Tahap selanjutnya adalah menerapkan pencarian *GridSearchCV* yang dikombinasikan dengan *Stratified 5-Fold Cross-Validation* untuk mencari konfigurasi parameter terbaik, khususnya pada KNN dan SVM.

	Model	Baseline Acc	Baseline F1	Optimized Accuracy	Optimized Macro-F1
0	K-Nearest Neighbors (KNN)	0.834928	0.816343	0.880383	0.872601
1	Gaussian Naive Bayes	0.500000	0.425072	0.636364	0.600555
2	Support Vector Machine (SVM)	0.928230	0.924547	0.971292	0.970010


Penerapan optimasi berhasil memberikan lonjakan performa pada seluruh algoritma. SVM secara sah terpilih sebagai model terbaik (*Best Model*) dengan raihan akurasi akhir 97.1% dan *Macro-F1* 97.0%. Konfigurasi parameter optimal yang ditemukan oleh *Grid Search* untuk SVM adalah $C=10$, $\gamma='auto'$, dan $kernel='rbf'$. Nilai *Macro-F1* (97.0%) yang sangat mendekati nilai Akurasinya (97.1%) membuktikan bahwa model SVM yang dihasilkan sangat seimbang, adil, dan tidak bias terhadap kelas tingkat obesitas manapun.

6.3 Visualisasi Performa dan *Confusion Matrix*

Berikut merupakan visualisasi *Confusion Matrix* sebelum di optimisasi:



Berikut visualisasi *Confusion Matrix* untuk SVM setelah di optimisasi:



Berdasarkan matriks kebingungan (*confusion matrix*) dari prediksi model SVM, terlihat bahwa garis diagonal utama (representasi prediksi yang benar atau *True Positives*) memiliki warna yang sangat pekat dengan angka tebakan yang tinggi. Model mampu mengklasifikasikan kelas ekstrem seperti *Insufficient Weight* dan *Obesity Type III* nyaris tanpa cacat. Hal ini wajar karena kedua kelas tersebut memiliki karakteristik fitur (*Weight* dan *Height*) yang batas matematisnya sangat jauh dari kelas lainnya.

6.4 Analisis Kesalahan (*Error Analysis*)

Meskipun model SVM mencapai tingkat akurasi 97.1%, masih terdapat sekitar 2.9% margin kesalahan (kegagalan klasifikasi). Analisis mendalam (*error analysis*) terhadap kasus-kasus yang gagal diprediksi ini sangat penting untuk mengungkap batasan model (*model limitations*):

1. Ambiguitas pada Batas Marginal Kelas (Borderline Cases): Mayoritas kesalahan prediksi (*misclassification*) tidak terjadi secara acak melompat jauh (misal: *Normal Weight* diprediksi menjadi *Obesity Type III*). Kesalahan terpusat secara eksklusif pada kelas-kelas yang saling bersebelahan, contohnya antara *Overweight Level II* dan *Obesity Type I*. Hal ini sangat masuk akal secara klinis, di mana individu dengan batas Indeks Massa Tubuh (IMT) transisional (misalnya IMT 29.9 berstatus *Overweight*,

sementara IMT 30.1 sudah masuk *Obesity*) memiliki profil kebiasaan makan (NCP, FAVC) dan aktivitas fisik (FAF) yang nyaris identik, sehingga algoritma kesulitan menarik batas keputusan (*decision boundary*) yang absolut. Optimasi Parameter (*Hyperparameter Tuning*): Menerapkan metode *GridSearchCV* atau *RandomizedSearchCV* untuk menemukan kombinasi parameter paling optimal (misal: mencari nilai K terbaik pada KNN atau kedalaman maksimal pada pohon keputusan) alih-alih menggunakan parameter bawaan (*default*).

2. Keterbatasan Atribut Gaya Hidup yang Subjektif: Beberapa fitur yang bersifat pelaporan mandiri (*self-reported*) seperti estimasi konsumsi air (CH_2O) dan frekuensi sayur (FCVC) memiliki rentang skala yang sempit (1 s.d. 3). Keterbatasan granualitas data subyektif ini membuat *Support Vector Machine* terkadang gagal membedakan pasien dengan berat badan berlebih yang memiliki pola kebiasaan yang sama dengan pasien berstatus normal, sehingga memicu terjadinya *False Positives*.

Sebagai mitigasi etik, fenomena kesalahan pada titik-titik marjinal inilah yang menjadi alasan utama mengapa model ini didesain semata-mata sebagai *Decision Support System* (skrining awal), dan hasil prediksinya tetap harus divalidasi dengan kalkulasi klinis oleh tenaga kesehatan profesional sebelum mengambil tindakan medis.

PEMBAHASAN

7.1 Evaluasi Model Terbaik dan Justifikasi Akademik

Berdasarkan serangkaian eksperimen yang telah dilakukan, *Support Vector Machine* (SVM) dengan konfigurasi hyperparameter *Grid Search* secara absolut ditetapkan sebagai model terbaik. Pencapaian Akurasi sebesar 97.1% dan *Macro-F1 Score* sebesar 97.0% menjadikannya sangat layak untuk diimplementasikan ke tahap *deployment*. Keunggulan SVM dibandingkan algoritma lainnya dapat dijelaskan melalui justifikasi akademik berikut:

1. Ketahanan terhadap Non-Linearitas (Kernel RBF): Kasus obesitas memiliki pola relasi yang kompleks dan non-linear antar-fiturnya. Sebagai contoh, intervensi frekuensi olahraga (FAF) dan konsumsi kalori tinggi (FAVC) tidak menghasilkan penurunan berat badan yang berbanding lurus dan konstan bagi setiap kelompok usia. Kernel *Radial Basis Function* (RBF) pada SVM mampu memetakan kompleksitas fitur-fitur ini ke dalam ruang dimensi yang lebih tinggi, sehingga model dapat membangun garis batas keputusan (*decision boundary*) multikelas yang sangat melengkung dan presisi. Hal ini tidak bisa dilakukan oleh model linier biasa atau KNN yang murni mengandalkan proksimitas jarak (*Euclidean distance*).
2. Parameter Penalti ($C=10$): Nilai $C=10$ yang ditemukan melalui *Grid Search* menunjukkan titik keseimbangan yang ideal (*Soft Margin*). Model diberikan kelonggaran penalti yang cukup agar tidak terlalu kaku terhadap anomali data (pencilan/ *outlier*), namun tetap tegas dalam memisahkan kelas-kelas margin yang tipis (seperti batas antara *Overweight Level II* dan *Obesity Type I*).

7.2 Analisis Trade-off: Akurasi, Kompleksitas, dan Interpretabilitas

Dalam pengembangan *Machine Learning*, tidak ada model yang sempurna tanpa adanya kompromi (*trade-off*). Keputusan memilih SVM dengan arsitektur kernel RBF dan *Grid Search* membawa konsekuensi yang telah dipertimbangkan secara matang:

- Akurasi vs. Kompleksitas Komputasi: Pencarian hyperparameter menggunakan *GridSearchCV* yang dikombinasikan dengan *Stratified 5-Fold Cross Validation* membutuhkan beban komputasi dan waktu pelatihan (*training time*) yang jauh lebih tinggi dibandingkan algoritma *baseline*. Namun, *trade-off* ini dinilai sangat sepadan. Kompleksitas waktu hanya terjadi satu kali di sisi *backend* (fase pelatihan), sedangkan performa model saat melakukan prediksi (fase inferensi) di aplikasi *frontend* Streamlit tetap berjalan dalam hitungan milidetik.
- Akurasi vs. Interpretabilitas (*Black-Box Effect*): Berbeda dengan algoritma *Decision Tree* atau *Logistic Regression* yang alur keputusannya dapat dibaca dengan mudah oleh manusia, arsitektur SVM berdimensi tinggi bertindak layaknya "kotak hitam" (*black-box*). Kita kehilangan kemampuan interpretasi matematis langsung tentang fitur mana yang paling dominan mempengaruhi keputusan model untuk satu individu tertentu. *Trade-off* ini diterima demi mengejar stabilitas dan akurasi 97.1%, dengan mitigasi etis berupa penyediaan visualisasi data pendukung dan kejelasan *Data Dictionary* pada aplikasi web agar pengguna tetap mendapatkan konteks klinis.

7.3 Implikasi terhadap Institusi Kesehatan

Kehadiran *Decision Support System* (DSS) berbasis model prediktif ini memberikan implikasi strategis dan praktis yang nyata bagi institusi kesehatan (seperti Puskesmas atau klinik gizi):

- Mengotomatiskan deteksi awal risiko obesitas masyarakat secara massal melalui kuesioner digital, sehingga tindakan preventif dapat diambil sebelum pasien jatuh sakit akibat komorbiditas.
- Akurasi multi-kelas yang tinggi membantu tenaga medis memprioritaskan alokasi waktu dan sumber daya pendampingan gizi khusus pada kelompok pasien berisiko ekstrem (*Obesity Type II & III*).
- Menegaskan peran sistem kecerdasan buatan murni sebagai instrumen pendukung untuk mempercepat skrining awal, tanpa mengeliminasi otoritas mutlak dokter atau ahli gizi dalam menentukan diagnosis final.

DESAIN APLIKASI DAN IMPLEMENTASI

8.1 Arsitektur Sistem dan *Backend*

Arsitektur perangkat lunak pada proyek ini memisahkan secara tegas antara lingkungan eksperimen (*Jupyter Notebook*), jalur pelatihan (*training pipeline*), dan jalur inferensi (*inference pipeline*).

1. Model SVM, *StandardScaler*, dan *LabelEncoder* yang telah dilatih dan dioptimasi tidak dihitung ulang setiap kali aplikasi berjalan. Ketiga komponen tersebut diekspor (diserialisasi) menjadi berkas biner berektensi `.joblib` dan disimpan di dalam direktori `models/`.
2. Logika inti aplikasi dipusatkan pada folder `src/`. Ketika pengguna memasukkan data, skrip `src/ml_core.py` akan mengambil alih untuk melakukan validasi input, mengubah data kategorikal menjadi numerik (*encoding*), dan melakukan

penskalaan fitur (*scaling*) secara presisi menggunakan parameter *scaler* asli dari data latih.

3. *Backend* aplikasi dibangun agar agnostik terhadap antarmuka. Model yang sama dapat diakses melalui antarmuka web interaktif berbasis Streamlit.


8.2 Alur Antarmuka Pengguna (UI/UX Flow)


Desain *User Interface* (UI) dan *User Experience* (UX) pada aplikasi web Streamlit dirancang agar bersih, intuitif, dan inklusif bagi masyarakat awam maupun tenaga medis. Alur pengguna ditetapkan sebagai berikut:

1. Beranda & Edukasi: Pengguna disambut dengan penjelasan singkat mengenai bahaya obesitas dan tujuan dari aplikasi *Decision Support System* ini.
2. Input Kuesioner Klinis: Pengguna mengisi formulir yang dibagi secara logis ke dalam tiga panel utama: (a) Demografi Fisik, (b) Kebiasaan Makan, dan (c) Gaya Hidup & Kondisi Fisik.
3. Pemrosesan Inferensi: Saat tombol "Analisis" ditekan, data mentah dikirim ke *backend* untuk diproses secara instan (dalam hitungan milidetik).
4. Visualisasi Hasil: Layar menampilkan tingkat obesitas pengguna (salah satu dari 7 kelas) dengan indikator warna yang sesuai.
5. Penegakan Etika (*Ethical Disclaimer*): Tepat di bawah hasil prediksi, aplikasi wajib menampilkan peringatan etis berhuruf tebal yang menyatakan bahwa hasil ini hanyalah skrining awal komplementer dan pengguna disarankan untuk berkonsultasi dengan dokter untuk diagnosis medis final.

8.3 Dokumentasi Aplikasi

Berikut adalah dokumentasi antarmuka dari aplikasi yang telah berhasil dijalankan:





8.4 Panduan Instalasi dan Cara Menjalankan Program

Aplikasi ini dirancang untuk dapat direproduksi dan dijalankan dengan mudah pada lingkungan lokal (*localhost*). Berikut adalah tahapan eksekusinya:

1. Persiapan Lingkungan (Prasyarat): Pastikan Python versi 3.9 hingga 3.11 telah terinstal. Buka terminal di dalam direktori root proyek dan instal seluruh pustaka dependensi yang dibutuhkan:

```
pip install -r requirements.txt
```
2. Menjalankan Antarmuka Utama (Streamlit):

```
streamlit run app_streamlit.py
```
3. Menjalankan Modul Retraining Otomatis:
 Jika di masa depan terdapat pembaruan dataset pada folder `data/`, model dapat dilatih ulang secara otomatis untuk memperbarui file `.joblib` dengan menjalankan skrip:

```
python src/train.py
```

KESIMPULAN

9.1 Capaian Outcome

Proyek ini telah berhasil mencapai *outcome* pembelajaran berupa perancangan dan implementasi *Decision Support System* (DSS) untuk deteksi dini tingkat obesitas. Melalui serangkaian eksperimen optimasi, algoritma Support Vector Machine (SVM) terpilih sebagai model terbaik dengan capaian Akurasi sebesar 97.1% dan *Macro-F1*

Score sebesar 97.0%. Nilai evaluasi yang seimbang ini membuktikan bahwa sistem yang dibangun bersifat *robust*, terhindar dari bias kelas minoritas, dan memenuhi standar kelayakan etis untuk di-*deploy* sebagai alat bantu skrining awal (bukan pengganti diagnosis medis).

9.2 Keterbatasan Penelitian

Meskipun memberikan performa klasifikasi yang sangat tinggi, implementasi model ini tetap memiliki beberapa batasan:

1. Bias Demografi Geografis: Dataset latih didominasi oleh responden dari wilayah Amerika Latin. Terdapat potensi penurunan akurasi jika model diterapkan secara langsung pada individu dari demografi ras atau benua lain (seperti Asia) akibat perbedaan genetika dan pola diet lokal.
2. Subjektivitas Data Masukan: Beberapa fitur krusial bersifat pelaporan mandiri (*self-reported*), seperti estimasi konsumsi air putih dan frekuensi makan sayur, yang rentan terhadap bias subjektivitas atau ketidakakuratan ingatan pengguna.

9.3 Rekomendasi Pengembangan

Untuk meningkatkan keandalan sistem di masa mendatang, terdapat dua rekomendasi utama:

1. Ekspansi dan Diversifikasi Dataset: Mengumpulkan atau menggabungkan data klinis dari demografi global yang lebih beragam untuk melatih ulang model, sehingga batas keputusan algoritma (*decision boundary*) menjadi lebih inklusif dan universal.
2. Integrasi Data Objektif (IoT): Menghubungkan *backend* aplikasi dengan perangkat kebugaran pintar (*wearable devices* atau *smartwatches*) untuk mengekstrak data aktivitas fisik dan pembakaran kalori secara otomatis dan objektif, guna meminimalisasi tingkat kesalahan pada data masukan pengguna.

LAMPIRAN

10.1 Kode Penting dan Link Repository

Link repository dan kode penting;

<https://github.com/SStynx/uas-ml-obesity>

10.2 Requirement

Berikut merupakan *requirement* yang dibutuhkan untuk menjalankan program:

1. streamlit==1.32.0
2. pandas==2.2.1
3. numpy==1.26.4
4. scikit-learn==1.4.1.post1
5. joblib==1.3.2

10.3 Demo dan Presentasi

Link presentasi dan demo:

https://drive.google.com/file/d/1_dYHw2hQR071sNT-UV3wiJBU2h8MqUaA/view?usp=sharing